Министерство цифрового развития, связи
и массовых коммуникаций Российской Федерации

Сибирский государственный университет
телекоммуникаций и информатики

Кафедра прикладной математики и кибернетики

ЛАБОРАТОРНАЯ РАБОТА №7

По дисциплине: «Программирование графических процессоров»

Выполнили:

Студенты 3 курса группы ИП-111
Корнилов А.А.,
Попов М.И.,
Толкач А.А.

Проверил:

Профессор кафедры ПМиК
Малков Е.А.

Новосибирск, 2024

Задание:

- Реализовать вычисление скалярного произведения векторов на GPU, используя CUDA API (“сырой код”) и, отдельно, используя библиотеку Thrust. Сравнить время выполнения программ при различной длине векторов.
- Реализовать транспонирование матрицы на GPU, используя CUDA API (“сырой код”) и, отдельно, используя библиотеку Thrust. Сравнить время выполнения программ при различной размерности матрицы.

Цель: освоить использование библиотеки Thrust.

Оборудование: Видеокарта GTX 1050TI (Pascal)

Выполнение работы:

Для выполнения работы был взят фрагмент программы с предыдущей лабораторной работы с сложением вектора размера (N*2^12)*(K*2^12), и из библиотеки Thrust был использован метод Transform для выбора матриц их начала и конца и оператор multiplies для их перемножения:

```
#include <thrust/generate.h>
#include <thrust/gather.h>
#include <thrust/device_vector.h>
#include <thrust/host_vector.h>
#include <cstdlib>
#include <iostream>
#include <iomanip>

using namespace std;

__global__ void gFunc(int *A, int *B, int *C, int N) {
    unsigned int i = threadIdx.x + blockIdx.x * blockDim.x;
    if (i >= N) return;
    C[i] = A[i] + B[i];
}

int main() {
    const int num = 1 << 12;
    int N = 4 * num, K = 8 * num, threads_per_block = 128;
    float elapsedTime = 0;
    cudaEvent_t start, stop;

    int *hA, *hB, *hC;
    int *A = (int *) calloc(N * K, sizeof(int));
    int *B = (int *) calloc(N * K, sizeof(int));
    int *C = (int *) calloc(N * K, sizeof(int));

    cudaMalloc((void **) &hA, N * K * sizeof(int));
    cudaMalloc((void **) &hB, N * K * sizeof(int));
    cudaMalloc((void **) &hC, N * K * sizeof(int));
```

```
    for (int i = 0; i < N; ++i) {
        A[i] = i;
        B[i] = i + 1;
    }

    cudaMemcpy(hA, A, N * K * sizeof(int), cudaMemcpyHostToDevice);
    cudaMemcpy(hB, B, N * K * sizeof(int), cudaMemcpyHostToDevice);

    cudaEventCreate(&start);
    cudaEventCreate(&stop);

    cudaEventRecord(start, 0);

    gFunc<<<dim3(threads_per_block),
            dim3((N * K + threads_per_block - 1) / threads_per_block)
         >>>(hA, hB, hC, N * K);
    cudaDeviceSynchronize();

    cudaEventRecord(stop, 0);
    cudaEventSynchronize(stop);

    cudaEventElapsedTime(&elapsedTime, start, stop);
    cout << "Time using raw CUDA code: " << setprecision(15) << elapsedTime <<
endl;
    elapsedTime = 0;

    cudaMemcpy(C, hC, N * K * sizeof(float), cudaMemcpyDeviceToHost);

    cudaFree(hA);
    cudaFree(hB);
    cudaFree(hC);

    thrust::host_vector<int> vA(A, A + N * K);
    thrust::host_vector<int> vB(B, B + N * K);
    thrust::host_vector<int> vC(N * K);

    thrust::device_vector<int> dA = vA;
    thrust::device_vector<int> dB = vB;
    thrust::device_vector<int> dC(N * K);

    cudaEventRecord(start, 0);
    thrust::transform(dA.begin(), dA.end(), dB.begin(), dC.begin(),
thrust::multiplies<int>());
    cudaDeviceSynchronize();

    cudaEventRecord(stop, 0);
    cudaEventSynchronize(stop);

    cudaEventElapsedTime(&elapsedTime, start, stop);
    cout << "Time using Thrust lib: " << setprecision(15) << elapsedTime << endl;
}
```

Листинг 1 – программа LR07_1.cu

Результат работы программы:

```
D:\Projects\CUDA_CMake\cmake-build-debug\LR07_GPU_1.exe
Time using raw CUDA code: 1.53593599796295
Time using Thrust lib: 175.661056518555

Process finished with exit code 0
```

К сожалению nvprof не получилось применить к программе.

По результату мы видим что программа с использованием библеотеки Thrust работает гораздо медленней, возможно из-за отсутствия выбрать количество нитей на блок

скалярного произведения векторов		
	CUDA	Thrust
1 << 2	1,234848022	0,114688002
1 << 4	1,079167962	0,516095996
1 << 6	1,146175981	0,091136001
1 << 8	1,253792048	0,315232009
1 << 10	2,063231945	4,273151875
1 << 12	39,45622253	186,9219818

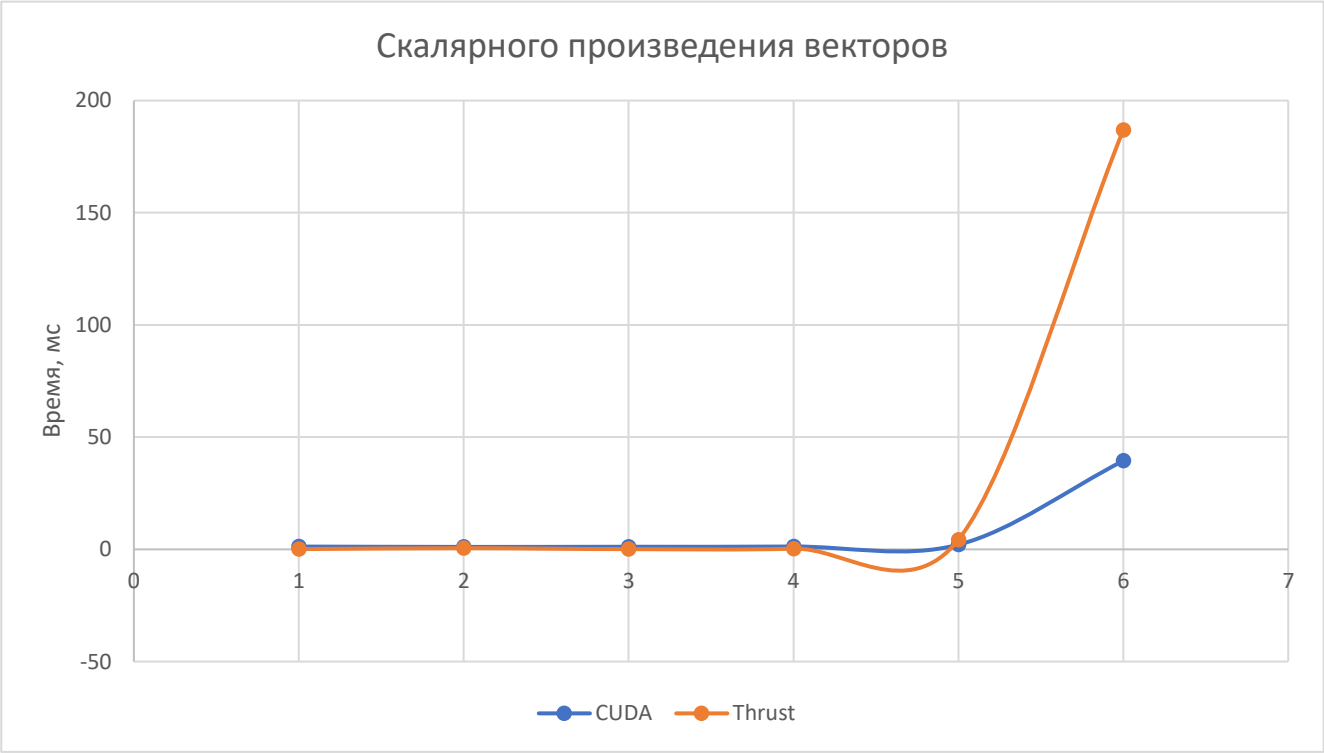

Также была собрана программа из прядущих лабораторных работ с транспонированием матрицы, использованием shared памяти и разрешением

конфликта банков, и из библиотеки Thrust была взята функция gather для копирования элементов d_map для транспонирования.

```
#include <cuda.h>
#include <thrust/host_vector.h>
#include <thrust/device_vector.h>
#include <thrust/copy.h>
#include <thrust/gather.h>
#include <iomanip>

#define CUDA_NUM 32

using namespace std;

__global__ void gFunc(int *A, int N, int K) {
    __shared__ int B[CUDA_NUM][CUDA_NUM + 1];
    unsigned int k = threadIdx.x + blockIdx.x * blockDim.x;
    unsigned int n = threadIdx.y + blockIdx.y * blockDim.y;
    if (k >= N || n >= K) return;

    B[threadIdx.y][threadIdx.x] = A[n + k * K];
    __syncthreads();
    A[k + n * N] = B[threadIdx.y][threadIdx.x];
}


int main() {
    const int num = 1 << 12;
    int N = 4 * num, K = 8 * num, threads_per_block = 128;
    float elapsedTime = 0;
    cudaEvent_t start, stop;

    int *map = (int *) calloc(N * K, sizeof(int));
    int *A = (int *) calloc(N * K, sizeof(int));

    int *hA;
    cudaMalloc((void **) &hA, K * N * sizeof(int));

    for (int i = 0; i < N; ++i) {
        for (int j = 0; j < K; ++j) {
            A[j + i * K] = j + i * K;
        }
    }

    cudaMemcpy(hA, A, N * K * sizeof(int), cudaMemcpyHostToDevice);

    cudaEventCreate(&start);
    cudaEventCreate(&stop);

    cudaEventRecord(start, 0);
    gFunc<<<dim3(threads_per_block, threads_per_block),
            dim3((N + threads_per_block - 1) / threads_per_block,(K +
threads_per_block - 1) / threads_per_block)
            >>>(hA, N,K);
```

```
    cudaDeviceSynchronize();

    cudaEventRecord(stop, 0);
    cudaEventSynchronize(stop);

    cudaEventElapsedTime(&elapsedTime, start, stop);
    cout << "Time using raw CUDA code: " << setprecision(15) << elapsedTime <<
endl;
    elapsedTime = 0;

    cudaMemcpy(A, hA, N * K * sizeof(float), cudaMemcpyDeviceToHost);

    free(A);
    cudaFree(hA);

    thrust::host_vector<int> vA(N * K);
    for (int i = 0; i < N * K; ++i) {
        vA[i] = i;
    }
    thrust::device_vector<int> dA = vA;
    thrust::device_vector<int> dA_T(N * K);


    for (int i = 0; i < K * N; ++i) {
        map[i] = (i % N) * K + (i / N);
    }

    thrust::device_vector<int> d_map(map, map + K * N);


    cudaEventRecord(start, 0);
    thrust::gather(d_map.begin(), d_map.end(), dA.begin(), dA_T.begin());
    cudaDeviceSynchronize();

    cudaEventRecord(stop, 0);
    cudaEventSynchronize(stop);

    cudaEventElapsedTime(&elapsedTime, start, stop);
    cout << "Time using Thrust lib: " << setprecision(15) << elapsedTime << endl;
}
```

Результат работы программы:

```
D:\Projects\CUDA_CMake\cmake-build-debug\LR07_GPU_2.exe
Time using raw CUDA code: 1.84943997859955
Time using Thrust lib: 599.636596679688

Process finished with exit code 0
```

К сожалению nvprof не получилось применить к программе.

транспонирование матрицы		
	CUDA	Thrust
1 << 2	0,975040019	0,175104007
1 << 4	0,889855981	0,076800004
1 << 6	1,47388804	0,111904003
1 << 8	1,601631999	0,478655994
1 << 10	2,158911943	8,643551826
1 << 12	1,600128055	602,6151733

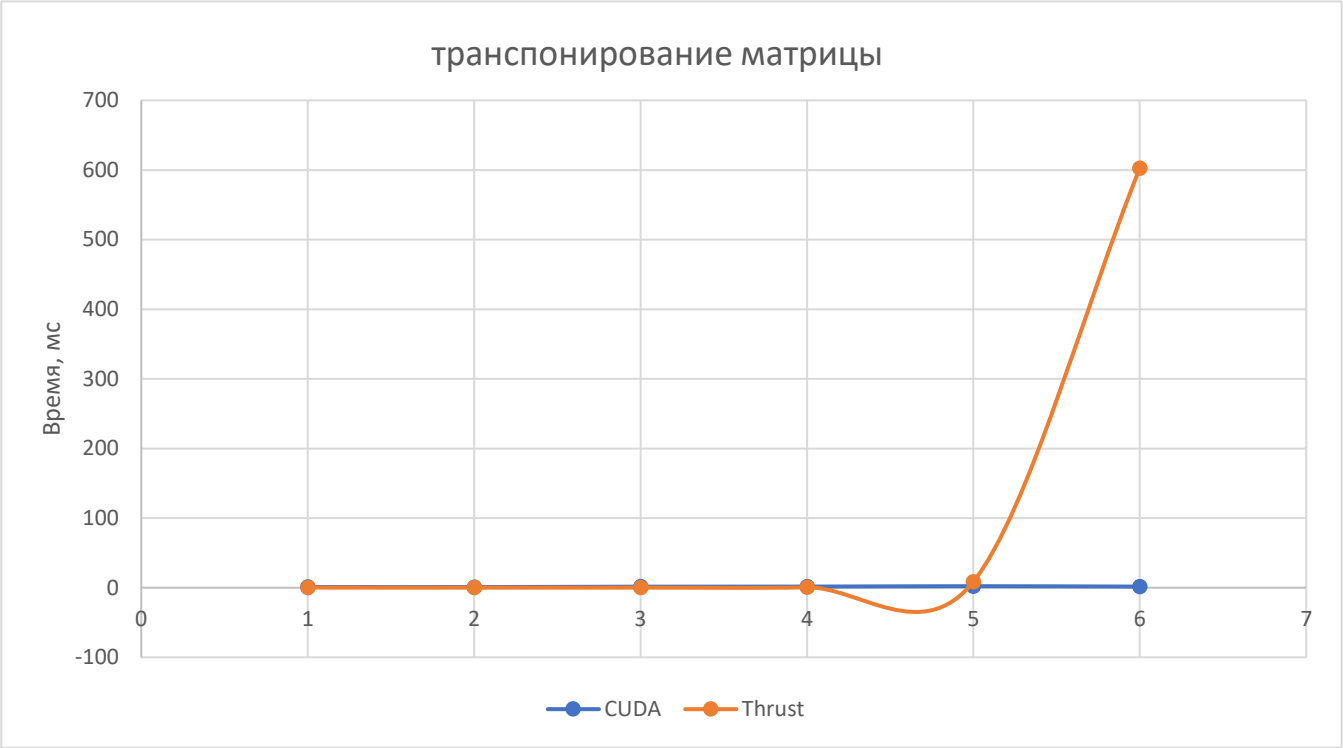

Тут также наблюдаем сильное снижение производительности при использовании библиотеки

Вывод: в ходе выполнения лабораторной работы, была исследована и применена работа с библиотекой Thrust, с методами device_vector для выделения памяти на видеоускорителе, host_vector для выделение памяти на хосте, метод transform для операция над массивами с указанием начала и конца и оператором multiplies умножением, и также метод gather для копирования. Библиотека thrust создана для облегчения работы вычислений с видеокартой, но имеет заметные отставания по производительности по с равнению с сырым CUDA кодом